

Discurso de Ódio no *Twitter* em Língua Inglesa: Detecção e Análise por Meio de Técnicas de *Machine Learning*

Anderson Soares de Santana Júnior¹, Antônio Carlos Bispo Cunha²,
Bruno Henrique Carneiro da Silva³, João Felipe Tunes Oliveira⁴, José Gustavo Abreu Alves⁵

¹ ¹Departamento de Computação (DCOMP) – Universidade Federal de Sergipe (UFS)
Av. Marechal Rondon, s/n – Jardim Rosa Elze – CEP 49100-000
São Cristóvão – SE – Brazil

{bruno.carneiro, joao.tunes}@dcomp.ufs.br

{antonio0407, and_soares, keysos}@academico.ufs.br

Resumo. *O estudo investiga a detecção automática de discurso de ódio em tweets em inglês usando Machine Learning e Transfer Learning. Analisa características linguísticas, ironia e abreviações que dificultam a classificação de mensagens ofensivas. Modelos pré-treinados como BERT, DistilBERT, e XLM-R são avaliados para identificar conteúdo discriminatório em larga escala.*

Palavras-chave: *Discurso de ódio, Redes sociais, Machine Learning, Transfer Learning.*

Abstract. *The study investigates automatic detection of hate speech in English tweets using Machine Learning and Transfer Learning. It analyzes linguistic features, irony, and abbreviations that hinder classification of offensive messages. Pre-trained models such as BERT, DistilBERT, and XLM-R are evaluated to identify discriminatory content at large scale.*

Keywords: *Hate speech, Social networks, Machine Learning, Transfer Learning.*

1. Introdução

O avanço das Tecnologias da Informação e Comunicação transformou a forma como informações são produzidas, distribuídas e consumidas, como já argumentava Manuel Castells ao destacar que essas tecnologias reconfiguram os processos de produção e difusão da informação, uma vez que “as funções e os processos dominantes na Era da Informação estão cada vez mais organizados em torno de redes” (CASTELLS, 1999). Nesse contexto, o discurso de ódio emerge como fenômeno, impulsionado pela ampla disseminação e pelo anonimato parcial proporcionados pelas redes sociais. Estudos mostram que grande parte desse conteúdo ofensivo é produzida em língua inglesa, em contextos de polarização social e eventos globais (Ali et al., 2022; Khanday et al., 2022).

Este trabalho concentra-se na investigação da detecção automática de discurso de ódio em inglês, com foco em dados do Twitter.

A questão de pesquisa que orienta este estudo é: como os modelos de Machine Learning identificam o discurso de ódio em língua inglesa no Twitter? Pesquisas apontam que a complexidade linguística e a velocidade de circulação das mensagens aumentam o problema, especialmente durante períodos de instabilidade social, como a pandemia de COVID-19 (Khanday et al., 2022). Usuários empregam ironias, gírias, abreviações e variações ortográficas para burlar sistemas automáticos de moderação, reduzindo o desempenho de métodos tradicionais (Ali et al., 2022). Estudos indicam a necessidade de abordagens baseadas em modelos pré-treinados e arquiteturas profundas para lidar com nuances semânticas.

O tema se justifica pela incidência de discurso de ódio nas redes sociais e pelas consequências sociais, psicológicas e políticas desse conteúdo em grupos vulneráveis (Ali et al., 2022). A disseminação de mensagens discriminatórias reforça estereótipos, aumenta tensões sociais e contribui para práticas de violência simbólica e discursiva em ambientes digitais (Ali et al., 2022). A pandemia aumentou comportamentos hostis e a circulação de narrativas ofensivas, tornando a detecção automática importante para reduzir impactos na sociedade (Khanday et al., 2022). Estudar métodos capazes de identificar e conter o fenômeno apresenta necessidade urgente.

A relevância científica deste estudo está no avanço de técnicas que combinam Machine Learning, Transfer Learning e Processamento de Linguagem Natural para lidar com desafios linguísticos (Ali et al., 2022). Pesquisas indicam que modelos como BERT, DistilBERT e XLM-R apresentam desempenho superior a algoritmos tradicionais, mas ainda enfrentam limitações com ambiguidade, ironia e criatividade linguística dos usuários (Ali et al., 2022). Resultados podem contribuir para sistemas de moderação automática em plataformas digitais, auxiliando na redução de conteúdo ofensivo. Grande parte da literatura trabalha com inglês, espanhol e árabe. Neste estudo, o foco está no inglês devido a três fatores: (1) grande volume de dados disponíveis; (2) ampla presença de pesquisas anteriores, permitindo comparação; (3) acesso a modelos amplamente treinados, com menor necessidade de adaptação. O objetivo do estudo é avaliar modelos de Machine Learning e Transfer Learning para detecção de discurso de ódio no Twitter, com base em tweets em inglês e nas abordagens de Ali et al. (2022) e Khanday et al. (2022). Os objetivos específicos são:

1. Identificar um conjunto de tweets em língua inglesa com discurso de ódio.
2. Aplicar algoritmos de *Machine Learning* para comparação de desempenho inicial.
3. Comparar os resultados obtidos com os achados de Ali et al. (2022) e Khanday et al. (2022).

2. Referencial Teórico

O referencial teórico apresenta conceitos, definições e abordagens aplicadas à detecção automática de discurso de ódio em tweets em inglês. Inicialmente, discute o contexto das Tecnologias da Informação e Comunicação (TIC) e plataformas digitais, com ênfase no Twitter como espaço de interação e debate público. Em seguida, aborda o discurso de ódio, sua propagação e impacto social. Posteriormente, apresenta técnicas de Machine Learning e Transfer Learning utilizadas na classificação de mensagens. Por fim, descreve desafios relacionados à análise automatizada de textos curtos, como complexidade linguística. O referencial fundamenta métodos aplicáveis à análise de tweets em inglês e à implementação de sistemas de detecção automática.

2.1. Tecnologias da Informação e Comunicação e Redes Sociais

As Tecnologias da Informação e Comunicação estruturam fluxos informacionais que definem modos de produção textual em ambientes digitais (CASTELLS, 1999). O Twitter apresenta organização baseada em mensagens curtas que circulam em ritmo contínuo. A plataforma permite observação direta de postagens públicas e formação de corpus amplo. A limitação de caracteres produz estruturas condensadas que influenciam análises textuais (DAVIDSON et al., 2017). Usuários escrevem com abreviações, símbolos e hashtags que alteram a composição do texto. A publicação ocorre em sequência rápida e gera volume elevado de dados, característica recorrente em ambientes digitais de interação pública (JENKINS et al., 2013). A estrutura digital permite coleta sistemática de mensagens. A dinâmica comunicacional condiciona métodos de preparação dos dados (ALI et al., 2022). O ambiente forma base para processos de classificação.

Plataformas digitais operam como espaços de circulação permanente de conteúdo produzido por usuários (JENKINS et al., 2013). O Twitter organiza linhas temporais abertas e acessíveis para observação de interações públicas. Usuários realizam respostas, menções e compartilhamentos que formam cadeias discursivas. A plataforma registra fluxos contínuos que compõem corpus utilizável em pesquisas (CASTELLS, 1999). A produção textual ocorre por mensagens breves que se conectam em redes amplas. O volume de dados possibilita identificação de padrões linguísticos, favorecendo análises computacionais em larga escala (MANSUR et al., 2023). A estrutura facilita coleta e armazenamento de mensagens. O ambiente permite análises voltadas a comportamentos discursivos. O conteúdo disponibilizado configura campo para investigação.

Textos em ambientes digitais apresentam variação linguística significativa (DAVIDSON et al., 2017). A informalidade do Twitter inclui abreviações, neologismos e emojis. O processamento automático precisa lidar com heterogeneidade textual. A representação adequada de dados melhora o desempenho de classificadores. Sistemas dependem de limpeza e normalização antes da análise (KHANDAY et al., 2022). Toraman

et al. (2022) mostram que variabilidade textual interfere na consistência de resultados. A extração de padrões linguísticos exige métodos robustos, especialmente em mensagens curtas e ruidosas (MANSUR et al., 2023). A forma reduzida dos tweets limita o contexto e reduz pistas semânticas. A análise precisa identificar relações relevantes entre tokens.

Transfer Learning permite adaptação de modelos pré-treinados a diferentes ambientes digitais (ALI et al., 2022). A técnica reduz a necessidade de treinar modelos do zero. A abordagem facilita a interpretação de textos curtos com padrões variados. Priyadarshini et al. (2023) indicam que ajustes de modelos melhoram a estabilidade de classificação. A utilização de embeddings contribui para a captação de proximidade semântica entre termos. A adaptação possibilita aplicação em plataformas distintas e domínios variados (YUAN et al., 2023). O ajuste direciona pesos internos para categorias específicas. Modelos pré-treinados capturam relações sintáticas e semânticas. O processo reduz custo computacional e melhora a viabilidade experimental.

As TIC influenciam formas de circulação de conteúdo e estruturam ambientes digitais propícios à análise discursiva (CASTELLS, 1999). O Twitter apresenta configuração que possibilita observação contínua de mensagens. A escrita breve gera formatos de alta densidade textual (DAVIDSON et al., 2017). A dinâmica da plataforma oferece corpus adequado para investigações linguísticas. A organização do ambiente determina estratégias de coleta e representação. O fluxo informacional orienta a delimitação dos processos analíticos. A produção acelerada de mensagens sustenta modelos supervisionados e pré-treinados, ampliando possibilidades de análise automatizada (ALI et al., 2022; YUAN et al., 2023). O conjunto estrutural da plataforma fornece campo para aplicação de técnicas de classificação. A base teórica fundamenta procedimentos metodológicos.

2.2. Discurso de Ódio no Twitter

O Twitter apresenta fluxo intenso de mensagens que incluem ataques direcionados relacionados a eventos públicos (MANSUR et al., 2023). A plataforma opera com postagens abertas que tornam visíveis práticas discursivas ofensivas. Usuários produzem mensagens curtas que facilitam formulações de conteúdo hostil (ALI et al., 2022). A estrutura reduzida dos tweets gera expressões condensadas que dificultam a interpretação automática. A divulgação ocorre em ritmo acelerado e amplia alcance textual. O formato da plataforma permite acesso contínuo ao conteúdo publicado, favorecendo observação sistemática do discurso (JENKINS et al., 2013). O corpus resultante possibilita análise de manifestações ofensivas. A composição dos tweets influencia padrões de escrita. A circulação do conteúdo cria cenário adequado para estudo da linguagem hostil (DAVIDSON et al., 2017).

Picos de mensagens ofensivas surgem em períodos de mobilização pública e produzem volume expressivo de ataques discursivos (KHANDAY et al., 2022). A plataforma

reúne publicações que refletem tensões sociais representadas linguisticamente. A curta extensão dos tweets concentra referências identitárias e termos agressivos. Usuários utilizam estratégias de abreviação que alteram sinais de hostilidade. A postagem ocorre de modo contínuo e gera sequências de insultos (KHANDAY et al., 2022). A estrutura digital favorece a difusão de conteúdos direcionados a grupos específicos. O conjunto de mensagens compõe material de análise para categorização. A linguagem empregada evidencia padrões recorrentes. A organização dos dados permite classificação por modelos (MUTANGA et al., 2022).

Eventos envolvendo disputas discursivas geram volume elevado de conteúdo hostil que se registra em intervalos curtos (ALI et al., 2022). Usuários reagem a acontecimentos públicos com mensagens ofensivas estruturadas por termos repetidos. A dinâmica do Twitter concentra respostas rápidas que intensificam a circulação textual. A produção de insultos ocorre por uso de palavras-chave que se replicam em diferentes postagens. A plataforma favorece a formação de temas por hashtags que agrupam discursos (JENKINS et al., 2013). A presença contínua de ataques produz amostras que permitem estudos quantitativos. A organização da timeline registra padrões recorrentes. O fluxo textual apresenta elementos relevantes para identificação automática. O ambiente expõe formas de hostilidade verbal (DAVIDSON et al., 2017).

A linguagem do Twitter inclui usos irônicos, termos abreviados e alterações ortográficas que dificultam o reconhecimento de hostilidade (KHANDAY et al., 2022). Usuários empregam sinais gráficos que deslocam sentidos aparentes. A escrita curta limita o contexto e reduz pistas semânticas. A variação textual interfere no desempenho de classificadores tradicionais (DAVIDSON et al., 2017). A presença de códigos informais modifica a estrutura do texto. A produção heterogênea exige técnicas de representação adequadas. A identificação automática depende de mecanismos que reconheçam padrões implícitos. A plataforma reúne conteúdo que desafia métodos estatísticos. A variabilidade transforma análise em processo complexo (MANSUR et al., 2023).

A ampla disponibilidade de dados no Twitter sustenta a criação de bases rotuladas utilizadas em estudos sobre discurso de ódio (ALI et al., 2022). O acesso ao conteúdo permite a formação de conjuntos destinados a treinamento e teste. A produção contínua de tweets gera material extenso que possibilita aplicação de técnicas de classificação. A coleta ocorre por procedimentos que extraem mensagens com termos específicos. A organização do corpus facilita a identificação de categorias de hostilidade. O ambiente oferece volume suficiente para comparação de algoritmos (MUTANGA et al., 2022). A produção textual permite análises replicáveis. O conjunto de dados se torna fundamento operacional para modelos automáticos (ALI et al., 2022). A plataforma fornece insumos para pesquisas empíricas.

2.3. *Machine Learning* aplicado à detecção de discurso de ódio

Modelos supervisionados utilizam conjuntos de dados rotulados para identificar padrões linguísticos em mensagens curtas (MANSUR et al., 2023). O texto é convertido em representações numéricas que permitem análise computacional. A classificação depende de vetores que registram distribuição de termos. A etapa de treinamento ajusta parâmetros para reduzir erros. O modelo organiza mensagens em categorias definidas no corpus. O processamento envolve segmentação e normalização do texto. A estrutura estatística orienta previsões futuras. KHANDAY et al. (2022) indicam que o aprendizado supervisionado identifica relações internas entre tokens. O procedimento gera resultados consistentes dentro do conjunto analisado (MUTANGA et al., 2022).

O uso de TF-IDF produz vetores que indicam importância relativa de palavras em relação ao corpus total. Os valores representam a presença e relevância das palavras em cada documento. A técnica opera sobre frequência e distribuição. A representação permite comparação entre mensagens curtas. A transformação remove a dependência de texto bruto. A matriz resultante organiza dados para etapas posteriores. A entrada vetorial estrutura classificadores lineares ou não lineares. A abordagem permite processamento eficiente de grandes volumes de dados (DAVIDSON et al., 2017). Yuan et al. (2023) mostram que TF-IDF fornece base sólida para classificação de textos.

Embeddings geram representações densas que registram relações semânticas entre tokens. Os vetores aproximam palavras com funções similares e separam termos com usos distintos. A técnica reduz a perda de informação presente em métodos esparsos. A representação permite a captação de padrões não detectáveis por frequência simples. A estrutura vetorial facilita a operação de classificadores profundos. O modelo utiliza aspectos contextuais incorporados no embedding. A abordagem cria espaço contínuo de relações entre termos. Priyadarshini et al. (2023) indicam que embeddings melhoram a interpretação de variações de escrita. A representação orienta procedimentos de aprendizado automático (YUAN et al., 2023).

Modelos supervisionados ajustam parâmetros internos comparando previsões com rótulos verdadeiros. A atualização ocorre por processos iterativos que minimizam erros. O mecanismo permite identificação de padrões recorrentes em mensagens curtas. A operação depende do cálculo de gradientes que alteram pesos internos. O sistema responde à estrutura do corpus e organiza categorias de saída. Yuan et al. (2023) indicam que a repetição de ciclos aprimora o desempenho do modelo. A técnica estabelece base para tarefas posteriores. O modelo aprende relações internas de tokens nos tweets. O ajuste fino orienta classificações consistentes em novos conjuntos (ALI et al., 2022).

A aplicação de Machine Learning possibilita análise de grandes coleções de tweets com procedimentos padronizados (MANSUR et al., 2023). O processamento automatizado organiza mensagens por regras estatísticas. A escala permite a identificação de

padrões não perceptíveis em análise manual. O corpus rotulado orienta classificação dos elementos analisados. A operação produz categorias aplicáveis a processos de moderação. O método reduz a necessidade de intervenção humana. KHANDAY et al. (2022) indicam que o procedimento fornece base para replicação em diferentes conjuntos. A abordagem fundamenta sistemas capazes de identificar hostilidade. O processamento estruturado permite consistência em avaliações subsequentes.

2.4. *Transfer Learning* e Modelos Pré-Treinados

Transfer Learning reutiliza modelos pré-treinados para aplicar conhecimento aprendido em grandes corpora a novas tarefas (MANSUR et al., 2023). O fine-tuning modifica parâmetros específicos do modelo para adaptação aos dados analisados, permitindo reconhecimento de padrões complexos em mensagens curtas. Representações semânticas previamente aprendidas ajudam na interpretação de relações entre tokens e na classificação de conteúdo. A técnica reduz a necessidade de treinar modelos do zero, tornando o processo mais eficiente em termos de tempo e recursos computacionais (ALI et al., 2022). Embeddings densos registram relações entre termos e orientam ajustes finos necessários para otimização da detecção (PRIYADARSHINI et al., 2023).

Modelos como BERT, DistilBERT e XLM-R aplicam Transfer Learning em textos curtos, ajustando pesos internos para adaptar representações pré-treinadas ao domínio dos dados. O modelo captura dependências entre tokens e relações contextuais, permitindo classificação precisa de mensagens ofensivas mesmo em presença de ironia ou abreviações (DAVIDSON et al., 2017). A reutilização do conhecimento prévio reduz o tempo de treinamento e a necessidade de grandes bases rotuladas, preservando aprendizado adquirido em corpora amplos. Ajustes estratégicos em camadas críticas aumentam a precisão do modelo e permitem análise consistente em diferentes conjuntos de dados (ALI et al., 2022).

O pré-treinamento em grandes corpora fornece representações ricas que registram relações semânticas e sintáticas entre palavras, e o fine-tuning permite que apenas parte dos parâmetros seja modificada, mantendo o aprendizado geral do modelo. Essa abordagem possibilita lidar com variações linguísticas típicas de redes sociais, como gírias e abreviações, sem comprometer a capacidade de classificação (MANSUR et al., 2023). Representações densas captam proximidade semântica entre tokens e distâncias entre termos distintos, organizando os dados para que o modelo identifique padrões complexos de discurso ofensivo (PRIYADARSHINI et al., 2023).

Modelos multilíngues como XLM-R permitem análise de textos provenientes de diferentes idiomas por compartilhamento de parâmetros (YUAN et al., 2023). A estrutura utiliza corpus amplo para aprender relações linguísticas variadas. O procedimento fornece vocabulário expandido que inclui tokens provenientes de múltiplos contextos. O processo permite aplicação em mensagens curtas com características distintas. O ajuste

final orienta o modelo para categorias específicas. A operação utiliza embeddings interoperáveis entre idiomas. O mecanismo facilita comparação entre diferentes conjuntos textuais. O modelo permite análise ampla em ambientes digitais. A técnica fornece suporte para tarefas de detecção (DEVIANTY, 2025).

O uso de Transfer Learning reduz necessidade de bases rotuladas extensas e permite adaptação rápida a novos contextos (ALI et al., 2022). O processo aproveita parâmetros aprendidos previamente. A aplicação permite interpretação de mensagens com variação estrutural. O ajuste do modelo concentra etapas em poucas camadas. A técnica estrutura procedimentos de classificação em fluxos organizados. O método viabiliza análises replicáveis em diferentes corpus (YUAN et al., 2023). O sistema utiliza padrões internos para identificação de categorias. O processo amplia o alcance da detecção automática. A abordagem compõe base metodológica para estudos de hostilidade verbal.

3. Trabalhos Relacionados

O tema central desta seção é a detecção automática de discurso de ódio no Twitter, que tem sido abordada por diferentes estudos empregando técnicas de aprendizado de máquina e deep learning. Pesquisas experimentais, como as de Mutanga et al. (2022) e Uzan e HaCohen-Kerner (2021), exploram abordagens baseadas em ensemble, LSTM e transformers para classificar tweets ou identificar usuários propagadores de conteúdo odioso. Revisões sistemáticas, como as conduzidas por Mansur et al. (2022) e Oliveira, Reis e Ebecken (2022), mapeiam métodos, algoritmos e tendências, destacando a predominância de classificadores tradicionais e a crescente adoção de modelos pré-treinados. Esses trabalhos evidenciam avanços na precisão e robustez das técnicas, ao mesmo tempo em que apontam desafios, como linguagem implícita, desequilíbrio de classes e limitação de conjuntos de dados, reforçando a relevância desta pesquisa para o desenvolvimento de modelos mais eficazes e generalizáveis.

(Mutanga et al., 2022) propõem um estudo experimental voltado à detecção automática de discurso de ódio no Twitter por meio de um método de ensemble baseado em votação. O modelo combina classificadores tradicionais de aprendizado de máquina, a saber, Regressão Logística, Árvores de Decisão e Máquinas de Vetores de Suporte, buscando explorar as forças complementares de cada técnica. A avaliação foi conduzida com dois conjuntos de dados rotulados: o HSO, contendo 11.310 tweets, e um subconjunto balanceado da base Kaggle, com 2.300 instâncias. Os resultados indicaram que o método proposto superou dez abordagens de linha de base, alcançando F1-score médio de 94,208% e precisão média de 94,212%. Como limitação, os autores destacam o uso da representação Bag of Words, que não captura adequadamente fenômenos linguísticos da linguagem informal dos tweets, além do custo computacional relativamente elevado no

treinamento.

(Mansur et al., 2022) apresentam uma Revisão Sistemática da Literatura sobre a detecção de discurso de ódio no Twitter, conduzida conforme as diretrizes de Kitchenham e Charters e o protocolo PRISMA. O estudo teve como objetivo mapear e sintetizar métodos, abordagens e técnicas utilizadas nessa tarefa, visando apoiar o desenvolvimento de modelos mais eficazes. A revisão analisou 91 artigos publicados entre 2015 e 2022, selecionados a partir de critérios que consideraram exclusivamente dados do Twitter e textos em língua inglesa. Os resultados indicam a inexistência de uma solução definitiva, com predominância de classificadores tradicionais de aprendizado de máquina, como Regressão Logística e Máquinas de Vetores de Suporte. As principais lacunas envolvem a linguagem ruidosa e implícita das redes sociais, o desequilíbrio entre classes, a falta de consenso conceitual e os desafios de generalização dos modelos.

(Uzan e HaCohen-Kerner, 2021) apresentam um estudo experimental voltado à detecção automática de propagadores de discurso de ódio no Twitter, empregando técnicas de aprendizado profundo e modelos baseados em transformers. O objetivo do trabalho consiste em identificar usuários que disseminam discurso de ódio de forma recorrente, deslocando o foco da análise do nível do tweet individual para o nível do autor. A amostra utilizada corresponde ao conjunto de dados disponibilizado pelo PAN CLEF 2021, composto por tweets em língua inglesa agregados por usuário. Para a tarefa de classificação, os autores avaliam modelos baseados em LSTM e no modelo BERT, considerando o histórico textual de cada conta. Os resultados indicam que a abordagem baseada em BERT apresenta desempenho superior ao LSTM, alcançando melhores valores de acurácia e F1-score. Como limitações, o estudo aponta a dependência de dados rotulados manualmente, a dificuldade em capturar sarcasmo e linguagem implícita, bem como possíveis vieses decorrentes do domínio e do contexto cultural do conjunto de dados.

(Oliveira, Reis e Ebecken, 2022) apresentam uma pesquisa de revisão sistemática sobre técnicas baseadas em aprendizado de máquina aplicadas à detecção de discurso de ódio no Twitter. O objetivo do estudo é analisar o estado da arte, identificando os principais métodos, algoritmos e tendências utilizados na literatura recente para a classificação automática de conteúdo odioso. A amostra do trabalho é composta por artigos científicos publicados entre 2015 e 2022, selecionados a partir de bases acadêmicas relevantes, conforme os critérios definidos pelos autores. Os resultados indicam que abordagens tradicionais de aprendizado de máquina, como SVM, Naive Bayes e Regressão Logística, ainda são amplamente utilizadas, embora métodos baseados em deep learning e modelos pré-treinados apresentem desempenho superior em cenários mais complexos. Além disso, o estudo destaca a relevância de técnicas de pré-processamento e representação textual na performance dos modelos. Como lacunas, os autores apontam a falta de padronização nos conjuntos de dados, a escassez de avaliações cross-dataset e a limitada exploração de

aspectos semânticos e contextuais da linguagem informal dos tweets.

De forma geral, os estudos revisados evidenciam que a maioria das pesquisas utiliza classificadores tradicionais de aprendizado de máquina ou modelos de deep learning e transformers, aplicados tanto a tweets individuais quanto a usuários propagadores de discurso de ódio. Apesar dos avanços em precisão e robustez, todos os trabalhos apontam desafios recorrentes, como linguagem implícita, sarcasmo, desequilíbrio de classes e limitações nos conjuntos de dados. Nesse contexto, a presente pesquisa busca preencher essas lacunas, explorando técnicas de representação textual mais sofisticadas e estratégias de classificação que combinam múltiplos níveis de análise (tweet e usuário), visando aumentar a generalização e a eficácia na detecção de discurso de ódio em inglês no Twitter, contribuindo para modelos mais precisos e aplicáveis em cenários reais.

4. Metodologia

4.1. Objetivo da Metodologia

Esta pesquisa tem como objetivo avaliar e comparar o desempenho de diferentes modelos de *Machine Learning* e *Deep Learning* na detecção automática de discurso de ódio em textos do Twitter. A metodologia adotada consiste na execução prática desses modelos em um ambiente computacional em nuvem, utilizando o Google Colab, que oferece servidores com capacidade de processamento suficiente para treinar e testar algoritmos de classificação de textos.

Foram selecionados modelos amplamente utilizados na literatura, incluindo classificadores baseados em representações TF-IDF e arquiteturas de redes neurais aplicadas ao Processamento de Linguagem Natural (PLN), permitindo a análise de desempenho, custo computacional e capacidade de generalização. Nesse ambiente, é possível importar bases de dados do Twitter, pré-processar os textos, treinar os modelos e acompanhar métricas de desempenho em tempo real, como acurácia, precisão, recall e F1-Score.

Essa abordagem metodológica permite a obtenção de resultados consistentes, possibilita a comparação entre diferentes técnicas e torna o estudo viável dentro das limitações de tempo e recursos de um projeto acadêmico, além de identificar as principais características e limitações de cada modelo na tarefa proposta.

4.2. Definição do Tipo de Pesquisa e Procedimento de Busca

4.2.1. Metodologia Base

Esta pesquisa caracteriza-se como um estudo experimental de natureza quantitativa, com foco na avaliação comparativa de modelos de *Machine Learning* e *Deep Learning* aplicados à detecção automática de discurso de ódio. A escolha dessa metodologia se justifica pela necessidade de testar, implementar e comparar diferentes algoritmos em um mesmo conjunto de dados, permitindo a análise objetiva do desempenho dos modelos por meio de métricas estatísticas padronizadas, como acurácia, precisão, recall e F1-Score.

Além disso, essa abordagem possibilita a obtenção de resultados confiáveis em um período reduzido, atendendo às limitações de tempo e recursos típicas de um estudo acadêmico.

As métricas utilizadas neste estudo são definidas da seguinte forma:

- **Acurácia:** porcentagem total de previsões corretas realizadas pelo modelo;
- **Precisão:** proporção de previsões positivas corretas em relação ao total de previsões positivas;
- **Recall:** proporção de instâncias positivas reais corretamente identificadas pelo modelo;
- **F1-Score:** média harmônica entre precisão e recall, utilizada para equilibrar ambas as métricas.

4.2.2. Procedimento de Busca (Acesso à Fonte de Dados)

O conjunto de dados utilizado nesta pesquisa foi obtido a partir de um arquivo no formato CSV, proveniente do estudo “*Automated Hate Speech Detection and the Problem of Offensive Language*”, desenvolvido por Davidson et al. (2017), da Cornell University. O dataset foi construído a partir da coleta de tweets contendo palavras-chave associadas ao discurso de ódio, utilizando um léxico elaborado por meio de *crowdsourcing*.

Posteriormente, uma amostra desses tweets foi rotulada, também por meio de *crowdsourcing*, em três categorias: discurso de ódio, linguagem ofensiva e ausência de discurso ofensivo. A utilização de um dataset secundário foi adotada devido à dificuldade prática e técnica de coletar, rotular e validar um conjunto de dados próprio, especialmente em função das restrições de acesso à API do Twitter, bem como das limitações de tempo e recursos computacionais.

Essa base foi escolhida por ser amplamente utilizada em estudos similares, possuir anotações humanas confiáveis e permitir comparações diretas com resultados encontrados na literatura científica.

O arquivo CSV foi importado para o ambiente de experimentação Google Colab, onde passou por etapas de pré-processamento textual, incluindo normalização do texto, tokenização, remoção de caracteres especiais, remoção de *stopwords* e transformação dos textos em representações numéricas adequadas para cada modelo avaliado.

4.2.3. Critérios de Inclusão e Exclusão

Critérios de Inclusão

- Tweets presentes no dataset original com rótulos válidos;
- Textos escritos em língua inglesa;
- Instâncias pertencentes às classes discurso de ódio, linguagem ofensiva e linguagem neutra.

Cr terios de Exclus o

- Registros duplicados ou com campos textuais vazios;
- Tweets com erros de formata  o ou r tulos inconsistentes;
- Conte dos n o textuais ou que n o se enquadram no objetivo da pesquisa.

4.2.4. Justificativa da Utiliza  o de Dataset Secund rio

A op  o por utilizar um dataset secund rio se justifica pela confiabilidade das anota  es humanas, pela ampla aceita  o na literatura cient fica e pela viabilidade metodol gica, permitindo que o foco da pesquisa seja direcionado   compara  o entre modelos de classifica  o, e n o ao processo complexo e oneroso de coleta e rotulagem de dados.

Dessa forma, foi poss vel garantir a validade dos resultados e cumprir os objetivos da pesquisa dentro de um prazo reduzido.

4.3. Extra  o e Armazenamento dos Dados (Fase de Campo)

A fase de campo desta pesquisa consistiu na extra  o, organiza  o e armazenamento dos dados experimentais gerados durante a execu  o dos modelos de *Machine Learning* e *Deep Learning* no ambiente computacional Google Colab.

4.3.1. Forma de Extra  o dos Dados

A extra  o dos dados ocorreu de maneira automatizada durante a execu  o dos experimentos no Google Colab. Scripts desenvolvidos em Python foram utilizados para importar o dataset no formato CSV, realizar o pr -processamento textual e treinar os modelos selecionados.

Ao final de cada execu  o, foram extra  das as principais m tricas de desempenho dos modelos, incluindo acur cia, precis o, recall e F1-Score, bem como informa  es relacionadas ao tempo de treinamento e ao custo computacional aproximado.

Esses dados foram registrados de forma estruturada por meio de planilhas eletr nicas, funcionando como um formul rio de extra  o padronizado.

4.3.2. Armazenamento e Organiza  o dos Dados

O armazenamento dos dados foi realizado em ambiente de nuvem, utilizando o Google Drive integrado ao Google Colab. Essa abordagem permitiu a centraliza  o dos arquivos de c digo, datasets pr -processados, resultados intermedi rios e m tricas finais em um  nico reposit rio.

Os arquivos foram organizados em pastas correspondentes a cada experimento, facilitando a rastreabilidade, a an lise posterior e a replica  o dos experimentos.

4.3.3. Justificativa da Estratégia de Extração e Armazenamento

A escolha por uma extração automatizada e armazenamento estruturado se justifica pela necessidade de padronização dos procedimentos experimentais e pela redução de vieses na coleta das métricas.

Além disso, o uso do Google Colab proporciona um ambiente reprodutível e amplamente utilizado em pesquisas em aprendizado de máquina, permitindo a execução eficiente dos modelos dentro das limitações de tempo e recursos computacionais do projeto.

4.4. Análise e Interpretação dos Dados (Resultados)

Após a fase de extração e armazenamento, os dados coletados foram examinados por meio de uma análise descritiva estatística, com o objetivo de avaliar e comparar o desempenho dos diferentes modelos de *Machine Learning* aplicados à detecção automática de discurso de ódio em textos do Twitter.

4.4.1. Tipo de Análise

O tipo de análise adotado foi a Análise Descritiva Estatística, baseada na comparação direta das métricas de desempenho geradas pelos modelos de classificação. Essa abordagem permite descrever, organizar e comparar quantitativamente os resultados obtidos, sem a intenção de realizar inferências estatísticas complexas.

4.4.2. Métricas e Variáveis Consideradas

As variáveis analisadas correspondem às métricas clássicas de avaliação de modelos de classificação, amplamente utilizadas na literatura de PLN:

- Acurácia;
- Precisão;
- Recall;
- F1-Score.

Essas métricas foram analisadas para os modelos Logistic Regression, Naive Bayes (Multinomial) e Support Vector Machine (SVM).

4.4.3. Interpretação dos Resultados

A análise dos resultados evidenciou diferenças significativas no desempenho dos modelos avaliados. O modelo Support Vector Machine (SVM) apresentou os melhores resultados globais, alcançando acurácia de 0.9009, precisão de 0.8855, recall de 0.9009 e F1-Score de 0.8858, indicando maior capacidade de generalização.

A Logistic Regression apresentou desempenho próximo ao SVM, com acurácia de 0.8925 e F1-Score de 0.8781, demonstrando ser um modelo robusto e eficiente para tarefas de classificação textual.

Por outro lado, o modelo Naive Bayes apresentou o menor desempenho geral, com acurácia de 0.8374 e F1-Score de 0.7968, especialmente na identificação correta da classe de discurso de ódio, devido à suposição de independência condicional entre as palavras.




Figura 1. Gráfico gerado pelo Google Colab com as informações obtidas pelo processamento do dataset

4.4.4. Justificativa da Abordagem Analítica

A escolha da análise descritiva estatística se justifica por sua adequação ao objetivo central da pesquisa, que consiste em comparar o desempenho de diferentes modelos de classificação.

O uso combinado de acurácia, precisão, recall e F1-Score possibilita uma análise equilibrada do desempenho dos modelos, evitando conclusões baseadas em uma única métrica.

4.5. Revisão e Referenciação

Esta seção tem como objetivo consolidar a metodologia adotada, assegurando que todas as etapas do estudo estejam descritas de forma clara, lógica e replicável, além de devidamente justificadas e fundamentadas na literatura científica. Também são apresentadas as principais referências utilizadas para embasar os métodos, técnicas e ferramentas empregadas ao longo da pesquisa

4.5.1. Passo a Passo Metodológico e Justificativa

A metodologia adotada neste estudo foi estruturada em etapas sequenciais e interdependentes, de modo a garantir clareza, consistência e replicabilidade dos procedimentos experimentais.

4.5.2. Definição do problema e objetivo da pesquisa

Inicialmente, definiu-se como objetivo principal avaliar e comparar o desempenho de diferentes modelos de *Machine Learning* aplicados à detecção automática de discurso de ódio em textos provenientes do Twitter. Essa definição norteou todas as decisões metodológicas subsequentes, desde a escolha do conjunto de dados até os critérios de avaliação dos modelos.

4.5.3. Seleção do conjunto de dados

Optou-se pela utilização de um dataset secundário amplamente reconhecido na literatura científica, proposto por Davidson et al. (2017), em função da confiabilidade de suas anotações humanas, da validação prévia em estudos semelhantes e da inviabilidade prática de realizar a coleta, rotulagem e validação de um conjunto de dados próprio. Essa escolha contribui para a validade externa da pesquisa e possibilita comparações diretas com resultados apresentados em trabalhos anteriores.

4.5.4. Ambiente computacional

Os experimentos foram conduzidos no ambiente computacional Google Colab, selecionado por oferecer infraestrutura em nuvem, facilidade de acesso, suporte às principais bibliotecas de aprendizado de máquina e possibilidade de reprodução dos experimentos sem a necessidade de hardware local específico. Essa característica torna o ambiente adequado para estudos experimentais em aprendizado de máquina, especialmente em contextos acadêmicos.

4.5.5. Pré-processamento dos dados

Após a definição do ambiente, o conjunto de dados foi submetido a etapas padronizadas de pré-processamento textual, incluindo normalização dos textos, remoção de caracteres especiais, tokenização e remoção de *stopwords*. Essas etapas são fundamentais para a redução de ruídos nos dados textuais e para a melhoria do desempenho dos modelos de classificação, uma vez que contribuem para a padronização do corpus e para a eliminação de informações irrelevantes. Tais procedimentos são amplamente recomendados na literatura de Processamento de Linguagem Natural e têm se mostrado eficazes em estudos relacionados à detecção de discurso de ódio em mídias sociais [?].

4.5.6. Representação dos textos

Posteriormente, os textos foram transformados em representações numéricas por meio da técnica TF-IDF (*Term Frequency–Inverse Document Frequency*), amplamente

empregada em tarefas de classificação textual por capturar a importância relativa dos termos dentro de um corpus, possibilitando que os algoritmos de aprendizado de máquina processem informações linguísticas de forma quantitativa.

4.5.7. Treinamento dos modelos

Na etapa de modelagem, foram treinados três modelos clássicos de classificação: *Logistic Regression*, *Naive Bayes* (Multinomial) e *Support Vector Machine* (SVM). A escolha desses modelos se justifica por sua ampla utilização em tarefas de Processamento de Linguagem Natural e por permitirem uma análise comparativa entre diferentes abordagens, incluindo modelos probabilísticos, lineares e baseados na maximização de margens.

4.5.8. Avaliação de desempenho

A avaliação de desempenho dos modelos foi realizada por meio de métricas padronizadas — acurácia, precisão, recall e F1-Score — que possibilitam uma análise quantitativa equilibrada, especialmente em cenários de classificação com múltiplas classes e possíveis desbalanceamentos.

4.5.9. Extração, armazenamento e análise dos resultados

Por fim, as métricas geradas durante os experimentos foram extraídas de forma automatizada, armazenadas em planilhas eletrônicas e analisadas por meio de análise descritiva estatística. Esse procedimento permitiu a comparação direta entre os modelos avaliados e a identificação daquele que apresentou o melhor desempenho global na tarefa de detecção automática de discurso de ódio.

Esse encadeamento metodológico assegura clareza, consistência e replicabilidade, atendendo aos critérios exigidos em pesquisas experimentais de natureza quantitativa.

4.5.10. Referenciação dos Métodos e Técnicas

Todos os métodos, técnicas e ferramentas adotados nesta pesquisa foram fundamentados em trabalhos consolidados da literatura científica. O uso do dataset proposto por Davidson et al. (2017) fundamenta-se em sua ampla adoção em estudos de detecção automática de discurso de ódio.

As métricas de avaliação seguem as recomendações clássicas para problemas de classificação supervisionada, conforme descrito por Géron (2019), que destaca a importância da análise conjunta de precisão, recall e F1-Score em cenários com múltiplas classes ou desbalanceamento.

5. Análise e Discussão dos Resultados

Nesta seção procedemos à análise e discussão dos resultados apresentados no estudo, organizando a investigação por pergunta de pesquisa, confrontando os achados empíricos com o referencial teórico e os trabalhos relacionados citados no documento original, e extraindo interpretações, explicações e implicações relevantes para o problema da detecção automática de discurso de ódio no Twitter. Os dados analisados provêm do(s) experimento(s) descrito(s) no PDF original — em particular, do uso do dataset de Davidson et al. e dos experimentos com modelos de *Machine Learning* (Logistic Regression, Naive Bayes, SVM), bem como das métricas de desempenho reportadas (acurácia, precisão, recall, F1). A análise que segue combina evidências quantitativas (resultados e métricas) com leitura crítica do estado da arte apresentada no mesmo documento.

5.1. Análise da Pergunta de Pesquisa 1 (RQ1)

O que se pretende investigar (RQ1). Com RQ1 pretende-se compreender qual é o desempenho relativo dos modelos clássicos de aprendizado supervisionado (Logistic Regression, Naive Bayes Multinomial e SVM) na tarefa de identificar discurso de ódio em tweets em inglês, quais tipos de erro são mais frequentes, e quais limitações inerentes aos modelos e aos dados explicam esses padrões. A relevância dessa questão reside em avaliar até que ponto abordagens mais simples (e computacionalmente econômicas) continuam sendo competitivas frente a necessidades práticas de moderação automática e estudos acadêmicos sobre o tema.

5.1.1. Visualização comparativa dos resultados

A organização dos resultados em dois gráficos de barras comparativos — o primeiro dedicado a modelos de *Machine Learning* clássico e o segundo a arquiteturas de *Deep Learning* — permite visualizar o desempenho global e a evolução da eficácia entre diferentes paradigmas de processamento. As métricas de precisão, recall e F1-score exibidas simultaneamente evidenciam os trade-offs entre a sensibilidade para identificar casos positivos e o rigor para evitar falsos positivos. Esta estrutura de visualização foi escolhida porque facilita a comparação direta entre modelos da mesma família e sustenta a análise sobre como representações de maior complexidade (embeddings) se comportam em relação aos *baselines* estatísticos, elementos que fundamentam a discussão interpretativa que segue.

5.1.2. Discussão dos Resultados

A discussão abaixo segue três eixos:

A — Desempenho agregado por modelo

Ranking generalizado dos modelos: Conforme os resultados reportados, o SVM apresen-




Figura 2 – Gráfico gerado pelo Google Colab com as informações obtidas pelo processamento do dataset.




Figura 2 – Gráfico gerado pelo Google Colab com as informações obtidas pelo processamento do dataset.

Figura 2. Gráfico gerado pelo Google Colab com as informações obtidas pelo processamento do dataset

tou o melhor desempenho geral (especialmente em F1-score macro), seguido por Logistic Regression como baseline robusto, com Naive Bayes obtendo desempenho inferior em cenários com linguagem curta e ruído típico do Twitter. Essa ordem concorda com a literatura aplicada a texto curto e esparsidade de features (ex.: representações TF-IDF), onde SVM tende a melhor separar classes em espaços de alta dimensionalidade.

Comportamento por métrica: Em termos de *precision*, modelos discriminativos (SVM, Logistic Regression) costumam controlar melhor falsos positivos em classes raras (*hate speech*) enquanto Naive Bayes, por sua suposição de independência e sensibilidade a distribuição de *tokens*, apresenta recall relativamente alto em classes majoritárias mas baixa precisão em classes menos frequentes — refletindo tendência a etiquetar excessivamente tweets como “offensive” quando há ambiguidade. Esses movimentos nas

métricas explicam o *trade-off* observado entre captura total de instâncias de ódio (*recall*) e confiança nas predições (*precision*).

Fragilidade em classes desequilibradas: O dataset utilizado contém classes com distribuição desigual (por exemplo, menos exemplos rotulados como *hate speech* em relação a *offensive* ou *neutral*). Os modelos, sem estratégias robustas de balanceamento ou penalização, tendem a otimizar para classes majoritárias, inflando acurácia global mas mascarando baixo desempenho em detecção de ódio — problema ressaltado no trabalho e consistente com estudos anteriores (cfr. Davidson et al., 2017). Portanto, interpretamos os números com cautela: F1 macro e métricas por classe são mais informativas que acurácia global.

B — Análise de erros e padrões linguísticos

Confusões recorrentes: *hate vs. offensive*: Apesar do bom desempenho geral dos modelos, observa-se dificuldade recorrente na distinção entre *hate speech* e *offensive language*. Linguisticamente, muitas expressões ofensivas não carregam intenção discriminatória explícita (ex.: “you are an idiot” vs. “all X should die”), e modelos baseados em n-gramas ou TF-IDF não capturam adequadamente intenção, alvo social ou contexto implícito. Isso contribui para que textos com palavras pejorativas, mas sem direcionamento discriminatório claro, sejam tratados como linguagem ofensiva, enquanto termos ambigualmente direcionados podem ser interpretados como discurso de ódio. A limitação em modelar explicitamente o alvo da ofensa e a intenção comunicativa constitui o principal fator explicativo desses erros.

Ironia, sarcasmo e eufemismos: A presença de ironia e eufemismos reduz dramaticamente a sensibilidade dos classificadores. Frases com superfície neutra podem carregar ódio implícito; sem modelagem contextual profunda (p.ex. embeddings contextualizados ou análise pragmática), modelos lineares tendem a falhar. Esse achado reitera a recomendação do referencial teórico de que *Transfer Learning* (BERT e variantes) capta melhor contexto, embora não tenha sido implementado empiricamente no experimento principal.

Ruído ortográfico, abreviações e emojis: A informalidade do Twitter (misspellings, *leetspeak*, abreviações, emojis como indicativos de tom) provoca dispersão nas *features* discretas. Modelos que tratam *tokens* de forma rígida (contador de n-gramas) perdem sinal — sugerindo que pré-processamentos mais sofisticados (normalização ortográfica, lematização, tratamento de emojis) e/ou *embeddings* subword são importantes para ganhos de robustez.

Viés e representatividade: Análises qualitativas mostram que termos culturalmente marcados e palavras de grupos vulneráveis podem induzir vieses: modelos podem gerar maior taxa de falsos positivos quando o vocabulário pertence a grupos historicamente estigmatizados, reproduzindo vieses do corpus de treino. O documento original comenta

a ausência de medidas formais de *fairness*, e aqui isso aparece como limitação crítica para aplicações de moderação.

C — Explicações metodológicas e diálogo com a literatura

Consistência com estudos prévios: Os padrões encontrados (SVM robusto; dificuldades frente a ironia e alvo implícito; confusão entre *hate* e *offensive*) estão alinhados com achados de Davidson et al. (2017) e com revisões da literatura sobre detecção de *hate speech*: modelos maduros melhoram com representação contextual e dados anotados com critérios claros. O documento original cita esses trabalhos e usa-os para justificar tanto escolhas metodológicas quanto as interpretações dos resultados.

Por que *Transfer Learning* não aparece empiricamente: O trabalho apresenta *Transfer Learning* e modelos pré-treinados (BERT, etc.) como caminho recomendado, mas não implementa tais modelos nos experimentos reportados — explicação metodológica plausível é limitação computacional ou de escopo. A ausência implica que os resultados representam uma base de comparação (*baseline*) útil, porém incompleta para avaliar o estado da arte. Essa lacuna é explicitamente reconhecida no próprio documento (e aqui reforçada como prioridade para trabalho futuro).

Implicações práticas: Para sistemas de moderação automatizada, as evidências sugerem que:

- Modelos clássicos podem servir como filtro inicial (baixo custo), mas serão insuficientes como única linha de ação.
- Integração com etapas humanas (curadoria de casos ambíguos) e com modelos contextualizados é necessária para reduzir falsos positivos em conteúdo sensível.
- Esforços de balanceamento e enriquecimento de dados (anotação focalizada em exemplos raros) são cruciais para melhorar *recall* em *hate speech* sem sacrificar *precision*.

5.1.3. Síntese da Pergunta de Pesquisa 1

RQ1 (retomada): Qual é o desempenho relativo dos modelos testados na detecção de discurso de ódio em tweets e quais são seus principais limites?

Resposta-síntese: Os modelos discriminativos clássicos (SVM, Logistic Regression) superam Naive Bayes no experimento em termos de F1 macro, com SVM entregando melhor separação global; contudo, todas as abordagens baseadas em TF-IDF e n-gramas falham sistematicamente em captar nuances de intenção, alvo e contexto pragmático (ironias, eufemismos), o que resulta em confusão frequente entre *hate speech* e *offensive language*, sensibilidade reduzida a ruído e risco de vieses. Em aplicação prática, os modelos testados são úteis como *baseline* e filtro, mas insuficientes para moderação autônoma sem técnicas complementares (*Transfer Learning*, pré-processamento linguístico, revisão humana).

5.2. Observações metodológicas gerais, limitações e recomendações

Limitações de anotação e definição: Como apontado no original, o uso de um dataset secundário (Davidson et al., 2017) traz vantagens (comparabilidade) e desvantagens (definições operacionais pré-fixadas). A ausência de reanotação ou de verificação inter-anotador reduz a capacidade de questionar rotulagem-fonte — recomendação: conduzir estudo de confiabilidade inter-anotador em amostras críticas.

Medidas métricas e análises faltantes: Faltou no experimento uma análise estatística inferencial (p.ex., testes de significância entre F1 de modelos) e uma análise qualitativa detalhada de falsas positivas/negativas com exemplos. Tais análises aumentariam a robustez das conclusões e permitiriam separar diferenças reais de flutuações amostrais.

Recomendações técnicas prioritárias:

- Implementar modelos contextualizados (BERT, RoBERTa, DistilBERT) e comparar com os *baselines* aqui testados; priorizar *fine-tuning* com estratégias de regularização e ajuste de classe desbalanceada.
- Enriquecer pré-processamento: normalização ortográfica, expansão de contrações, tratamento de emojis/hashtags e tokenização subword.
- Anotações adicionais: criar subconjunto anotado com marcação de alvo e intenção, útil para treinar modelos *multi-task* (classificação de discurso de ódio + detecção de alvo).
- Avaliação ética: incluir métricas de *fairness* e análises por subgrupos linguísticos/demográficos para identificar vieses.

Implicações teóricas: Os resultados reforçam a tese de que a tarefa de detecção de discurso de ódio é, antes de tudo, um problema pragmático e contextual — algo que modelos puramente léxicos têm dificuldade de representar. Isso corrobora a necessidade de aproximação interdisciplinar (PLN + estudos sociais) para definir categorias anotáveis e consequências de classificação.

5.3. Conclusão

A análise mostrou padrões claros de desempenho (SVM e Logistic Regression e Naive Bayes em termos gerais) e revelou limitações conceituais e técnicas (contexto, ironia, alvo, viés) que impedem a adoção segura dos modelos testados como solução final para moderação de *hate speech*. Essas conclusões contextualizam e justificam a necessidade de avanços que tipicamente aparecem em *Trends and Validations* — assunto que, conforme combinado, ficará a cargo da próxima etapa (Seção 6). As recomendações técnicas e metodológicas apontadas aqui (uso de *Transfer Learning*, reanotação, análises de *fairness* e testes estatísticos) devem orientar e ser incorporadas na Seção 6 para validar tendências e caminhos propostos.

6. Trends e Validations

A presente seção tem como objetivo identificar padrões recorrentes nos resultados obtidos e validar empiricamente o desempenho dos modelos propostos, distinguindo a análise de tendências da etapa de verificação de consistência frente a estudos consolidados na literatura. A identificação de tendências permite observar comportamentos sistemáticos nos dados e nos classificadores, enquanto a validação confronta esses achados com evidências previamente reportadas em pesquisas sobre detecção automática de discurso de ódio em redes sociais (DAVIDSON et al., 2017). No contexto de abordagens baseadas em aprendizado de máquina e transferência de aprendizado, essa distinção é essencial para avaliar a generalização e a confiabilidade dos modelos em diferentes cenários e bases de dados (ALI et al., 2022). Dessa forma, esta seção contribui para reforçar a robustez metodológica, a consistência dos resultados e a credibilidade científica do estudo.

6.1. Tendências

No contexto desta pesquisa, o termo “tendências” refere-se a padrões recorrentes observados no desempenho dos modelos de classificação, identificados a partir da análise sistemática das métricas obtidas e da comparação entre diferentes algoritmos. Em estudos de detecção automática de discurso de ódio, a observação de regularidades no comportamento dos classificadores permite identificar características estruturais dos dados e limitações inerentes aos modelos, indicando comportamentos estáveis e não aleatórios (DAVIDSON et al., 2017). Em abordagens de aprendizado de máquina, tais tendências são fundamentais para avaliar a capacidade de generalização e a robustez dos métodos frente à complexidade linguística das redes sociais (GÉRON, 2019). Neste trabalho, as tendências foram extraídas por meio da análise comparativa dos resultados e da identificação de padrões de desempenho recorrentes entre os modelos avaliados.

As tendências analisadas foram derivadas das métricas de acurácia, precisão, recall e F1-Score obtidas pelos modelos Logistic Regression, Naive Bayes e Support Vector Machine, aplicados ao conjunto de dados proposto por Davidson et al. (2017). Considerou-se como tendência todo padrão que se repetiu de forma consistente entre diferentes métricas e classes, apresentando impacto relevante no desempenho global dos classificadores. Como critérios, adotaram-se a recorrência dos resultados entre modelos, a intensidade das diferenças observadas nas métricas e sua influência na identificação da classe de discurso de ódio, conforme procedimentos comuns em estudos comparativos da área (Mansur et al., 2023). Os resultados foram organizados de modo a permitir a categorização das tendências segundo sua frequência e relevância.

A análise permitiu identificar três tendências centrais: (i) desempenho superior de modelos lineares discriminativos, especialmente o Support Vector Machine, em relação a abordagens probabilísticas; (ii) maior dificuldade na classificação correta da classe “discurso de ódio” quando comparada às classes “ofensivo” e “neutro”; e (iii) maior

equilíbrio entre precisão e recall nos modelos baseados em maximização de margens. Essas tendências são evidenciadas pelos resultados apresentados na Seção 5, nos quais o SVM obteve os maiores valores de acurácia e F1-Score, enquanto o Naive Bayes apresentou desempenho inferior, sobretudo na identificação de instâncias de ódio. Achados semelhantes são reportados por (Davidson et al., 2017) e (Khanday et al., 2022), que destacam a maior robustez de classificadores discriminativos em tarefas de classificação sensíveis ao contexto semântico.

Do ponto de vista interpretativo, essas tendências indicam que modelos capazes de aprender fronteiras de decisão mais precisas entre classes semanticamente próximas apresentam maior adequação para a tarefa de detecção de discurso de ódio. A dificuldade recorrente na distinção da classe de ódio evidencia a complexidade linguística e pragmática desse fenômeno em ambientes digitais, marcada por ambiguidades e sobreposição semântica, conforme discutido em estudos recentes baseados em transferência de aprendizado (ALI et al., 2022). Tais padrões sugerem limitações de representações baseadas apenas em frequência de termos e apontam para a necessidade de modelos que incorporem informações contextuais mais profundas. Em termos práticos, essas tendências reforçam a importância da escolha criteriosa dos algoritmos em sistemas automáticos de moderação de conteúdo; teoricamente, indicam a relevância de avanços em técnicas de representação semântica para o aprimoramento da detecção de discurso de ódio em redes sociais.

6.2. Validação dos resultados

A validação dos resultados é uma etapa necessária em estudos experimentais de aprendizado de máquina, especialmente em tarefas sensíveis como a detecção automática de discurso de ódio, pois garante que os achados não sejam fruto de vieses metodológicos, escolhas arbitrárias de modelos ou características específicas de um único conjunto de dados. Em contextos de Processamento de Linguagem Natural aplicado a redes sociais, a validação permite avaliar a confiabilidade, a consistência e a capacidade de generalização dos modelos, assegurando que o desempenho observado reflita padrões reais do fenômeno analisado e não apenas ajustes circunstanciais ao corpus utilizado. Além disso, a validação é fundamental para conferir legitimidade científica aos resultados, possibilitando sua comparação com a literatura existente e sua eventual aplicação em cenários práticos de moderação automática de conteúdo.

Os resultados obtidos neste estudo foram validados principalmente por meio da comparação sistemática com trabalhos relacionados e do uso de dados públicos amplamente reconhecidos na literatura. Inicialmente, o desempenho dos modelos avaliados (Logistic Regression, Naive Bayes e SVM) foi confrontado com os achados reportados por Davidson et al. (2017), Mutanga et al. (2022) e Mansur et al. (2023), observando-se convergência nos padrões de desempenho, especialmente quanto à superioridade de

modelos discriminativos e às dificuldades recorrentes na distinção entre discurso de ódio e linguagem ofensiva. A utilização do dataset público de Davidson et al. (2017), amplamente empregado em estudos similares, contribuiu para a validade dos resultados ao permitir comparações diretas com pesquisas consolidadas. Adicionalmente, a validação ocorreu de forma implícita pela adoção de métricas padronizadas e aceitas pela comunidade científica (acurácia, precisão, recall e F1-Score), bem como pela replicabilidade dos experimentos em ambiente controlado (Google Colab), possibilitando a reprodução dos resultados por outros pesquisadores.

No que se refere às ameaças à validade, algumas limitações devem ser consideradas. Quanto à validade interna, possíveis ameaças estão relacionadas à escolha de modelos clássicos e à ausência de técnicas avançadas de balanceamento de classes ou ajuste de hiperparâmetros mais sofisticados, o que pode influenciar o desempenho observado. A validade externa é limitada pelo uso de um único dataset em língua inglesa e proveniente de um contexto específico do Twitter, o que restringe a generalização dos resultados para outras plataformas, idiomas ou períodos temporais. A validade de construção pode ser afetada pelas definições operacionais das classes “discurso de ódio” e “linguagem ofensiva” adotadas no dataset, uma vez que tais conceitos são complexos e sujeitos a interpretações culturais e contextuais distintas. Por fim, a validade de conclusão apresenta limitações decorrentes da ausência de testes estatísticos inferenciais para verificar a significância das diferenças entre os modelos, o que sugere cautela na interpretação de pequenas variações nas métricas. Ainda assim, o alinhamento dos resultados com a literatura e a transparência metodológica contribuem para mitigar essas ameaças e reforçar a confiabilidade geral do estudo.

7. Conclusão

A detecção automática de discurso de ódio em redes sociais apresenta desafios significativos devido à natureza curta, informal e ambígua dos textos produzidos nesses ambientes. Diante desse cenário, este trabalho analisou a aplicação de modelos de Machine Learning à classificação de tweets em língua inglesa, com o objetivo de avaliar sua capacidade de identificar padrões associados a mensagens ofensivas e discriminatórias a partir de representações textuais amplamente adotadas na literatura.

Os experimentos realizados indicaram que as abordagens empregadas conseguem distinguir de forma consistente entre os diferentes tipos de conteúdo analisados, evidenciando a adequação dos modelos à tarefa proposta. Observou-se que modelos discriminativos apresentam maior estabilidade na separação das classes, enquanto abordagens probabilísticas se mostram mais sensíveis às limitações impostas pela representação léxica utilizada, especialmente em um contexto caracterizado por elevada variabilidade textual.

Do ponto de vista científico, os resultados reforçam discussões já consolidadas no

âmbito do Processamento de Linguagem Natural, ao evidenciar a viabilidade de técnicas clássicas de aprendizado supervisionado na detecção de discurso de ódio em mídias sociais. Além disso, a estrutura metodológica adotada contribui para a sistematização de estudos comparativos, oferecendo uma base clara e replicável para pesquisas futuras, ao mesmo tempo em que aponta implicações práticas relevantes para o apoio à moderação automática de conteúdo em plataformas digitais.

Ainda assim, os achados devem ser interpretados considerando as limitações do estudo, relacionadas tanto ao uso de um conjunto de dados específico quanto à adoção de representações baseadas em TF-IDF, que restringem a captura de fenômenos linguísticos mais complexos. Nesse sentido, investigações futuras podem explorar modelos baseados em Transfer Learning, bem como a avaliação em diferentes bases de dados e cenários de generalização, de modo a ampliar a robustez e a aplicabilidade dos sistemas de detecção automática de discurso de ódio.

8. Referências Bibliográficas

ALI, Raza; FAROOQ, Umar; ARSHAD, Umair; SHAHZAD, Waseem; BEG, Mirza Omer. Hate speech detection on Twitter using transfer learning. *Computer Speech & Language*, v. 74, p. 101365, jul. 2022. DOI: 10.1016/j.csl.2022.101365.

KHANDAY, Akib Mohi Ud Din; RABANI, Syed Tanzeel; KHAN, Qamar Rayees; MALIK, Showkat Hassan. Detecting Twitter hate speech in COVID-19 era using machine learning and ensemble learning techniques. *International Journal of Information Management Data Insights*, v. 2, n. 2, p. 100120, nov. 2022. DOI: 10.1016/j.jjime.2022.100120.

PRIYADARSHINI, I.; SAHU, S.; KUMAR, R. A transfer learning approach for detecting offensive and hate speech on social media platforms. *Multimedia Tools and Applications*, 2023.

DEVIANTY, Fairuz Astari. Transfer Learning Methods for Hate Speech Detection in Bahasa Indonesia. *Journal of Information Technology and Computer Science*, 2025.

YUAN, Lanqin; WANG, Tian; FERRARO, Giovanni et al. Transfer learning for hate speech detection in social media. *Journal of Computational Social Science*, v. 6, p. 1081–1101, 2023.

CASTELLS, Manuel. *A sociedade em rede*. 2. ed. São Paulo: Paz e Terra, 1999. (A Era da Informação: Economia, Sociedade e Cultura; v. 1). Jenkins, Henry; Ford, Sam; Green, Joshua. *Spreadable Media: Creating Value and Meaning in a Networked Culture*. New York: New York University Press, 2013.

DAVIDSON, Thomas et al. Automated hate speech detection and the problem of offensive language. In: *Proceedings of the 11th International AAAI Conference on Web and Social Media (ICWSM)*. Montréal, Canada, 2017.

MUTANGA, Raymond T.; NAICKER, Nalindren; OLUGBARA, Oludayo O. Detecting hate speech on Twitter network using ensemble machine learning. *International Journal of Advanced Computer Science and Applications*, v. 13, n. 3, p. 331–339, 2022.

MANSUR, Zainab; OMAR, Nazlia; TIUN, Sabrina. Twitter hate speech detection: a systematic review of methods, taxonomy analysis, challenges, and opportunities. *IEEE Access*, v. 11, 2023. DOI: 10.1109/ACCESS.2023.3239375.

GÉRON, Aurélien. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. 2. ed. Sebastopol: O'Reilly Media, 2019.